

EcoDrones

Sistema de Monitoreo Ambiental con Drones

Detección Temprana de Focos Ígneos y Protección de Biodiversidad

Capilla del Monte / Cerro Uritorco — Córdoba, Argentina

Trabajo Práctico — Etapa Final

Universidad Argentina De la Empresa (UADE)

Materia: Ingeniería de Datos 2

Profesor: Fernández Alfonso Martín

Grupo: Piña Matias, Vazquez Luciana, Micheli Alejo Gonzalo, Lambert Theo, Huertas Maximiliano Ivan, D'Elia Tomas

Curso: 2026 C1 — Lunes Tarde

Fecha de entrega: Junio 2026

Etapas: Final

2. Resumen Ejecutivo

Las sierras de Córdoba enfrentan incendios forestales recurrentes que amenazan la biodiversidad local y las comunidades aledañas. Los mecanismos actuales de detección tienen latencias de horas, insuficientes para una respuesta oportuna.

EcoDrones es una plataforma de vigilancia ambiental que integra 3 drones autónomos con sensores diferenciados, dos bases de datos NoSQL (MongoDB y Neo4j) y un dashboard táctico en tiempo real. La solución detecta anomalías térmicas en menos de 1 segundo, predice la propagación del fuego mediante análisis de grafos e identifica automáticamente la fauna en peligro.

El valor de la arquitectura reside en la integración bidireccional: MongoDB ingiere telemetría masiva a alta velocidad mientras Neo4j resuelve consultas de propagación y relaciones ecológicas que serían costosas en un modelo relacional. Esta **arquitectura de persistencia políglota** asigna a cada motor un rol especializado según la naturaleza del dato, siguiendo el principio de **diseño orientado a consultas**: primero se identificaron los patrones de acceso y luego se diseñaron las estructuras optimizadas para responderlos.

3. Alcance Definitivo del Proyecto

Incluye (funcionalidades demostradas):

- Simulación de telemetría IoT con 3 drones de hardware diferente (esquema flexible).
- Ingestión en MongoDB a 3 documentos/segundo con objetos embebidos GeoJSON.
- Detección automática de incendios (umbral >45°C) con polling continuo.
- Modelado de ecosistema en Neo4j: 6 zonas, 7 especies autóctonas, relaciones topológicas direccionales.
- Análisis predictivo de propagación en cascada (2 saltos) según vector de viento.
- Integración bidireccional MongoDB ↔ Neo4j en tiempo real.
- Dashboard táctico con 4 pestañas: Monitoreo, Alertas, Mapa Operativo, Propagación.
- Panel de acciones de respuesta recomendadas ante incendio.
- Orquestación completa con Docker (un solo comando para levantar/detener).

No incluye (fuera del alcance):

- Hardware real de drones ni control de vuelo físico.
- Integración con sistemas de bomberos o APIs meteorológicas reales.
- Procesamiento de imágenes térmicas o satelitales.
- Autenticación de usuarios ni multi-tenancy.
- Despliegue en cluster productivo (se ejecuta en ambiente local Docker).

4. Objetivos Técnicos (Comprobables)

Cada objetivo está redactado como resultado verificable con consulta, script y evidencia:

#	Objetivo	Cómo se verifica
1	Ingerir telemetría de 3 drones con estructura diferente en la misma colección	Consultar MongoDB y ver documentos con campos distintos (UV en Beta, PM2.5 en Gamma)
2	Detectar temperatura >45°C en menos de 2 segundos desde la inserción	Observar en monitor_alertas.py que la alerta se dispara en el ciclo inmediato
3	Predecir zona de propagación según dirección de viento actual	Consulta Cypher: MATCH (z)-[:LIMITA_CON {direccion: \$dir}]->(vecina) RETURN vecina
4	Identificar fauna en riesgo directo y en zona de propagación	Consulta Cypher: traversal 2 saltos + HABITA_EN, retorna especies con IUCN
5	Escribir resultado de Neo4j de vuelta en MongoDB (integración bidireccional)	Consultar alertas_disparadas y verificar campo analisis_neo4j embebido
6	Visualizar posición GPS de drones en mapa satelital en tiempo real	Dashboard pestaña Mapa Operativo con puntos moviéndose

5. Dataset Utilizado (Simulado)

Contexto Big Data — Las 5V

EcoDrones se enmarca en las 5 dimensiones del Big Data: **Volumen** (259.200 docs/día, escalable a millones con más drones), **Velocidad** (3 docs/seg en near-real-time), **Variedad** (esquema flexible por modelo de dron + grafo topológico + GeoJSON), **Veracidad** (modelo físico correlacionado, no aleatorio) y **Valor** (detección temprana de incendios para proteger ecosistemas y comunidades).

Criterio de simulación

Los datos son generados por `simulador_continuo.py` usando un modelo físico de decaimiento exponencial de temperatura según la distancia al foco de incendio (ZONA_003). No son datos aleatorios triviales: las variables están correlacionadas físicamente (a mayor cercanía al foco → mayor temperatura, mayor CO2, menor humedad, mayor velocidad de viento).

Volumen y frecuencia

Métrica	Valor
Frecuencia de generación	1 ráfaga/segundo (3 documentos por ráfaga, uno por dron)
Registros por minuto	~180 documentos
Registros por hora	~10.800 documentos
Registros por día (24h)	~259.200 documentos
Período temporal cubierto	Continuo mientras el simulador esté activo
Volumen por documento	~350 bytes (ALPHA) / ~420 bytes (BETA/GAMMA con sensores extra)
Volumen diario estimado (MongoDB)	~95 MB

Entidades generadas

Entidad	Motor	Cantidad	Naturaleza
Documentos de telemetría	MongoDB	Creciente (~3/seg)	Dinámica
Documentos de alerta	MongoDB	Creciente (basado en eventos)	Dinámica
Nodos :Zona	Neo4j	6	Estática
Nodos :Especie	Neo4j	7	Estática
Nodos :Dron	Neo4j	3	Estática
Nodos :Lectura	Neo4j	Creciente (solo alertas)	Dinámica
Nodos :Alerta	Neo4j	Creciente (solo alertas)	Dinámica
Relaciones [:LIMITA_CON]	Neo4j	14 (bidireccionales)	Estática
Relaciones [:HABITA_EN]	Neo4j	13	Estática

Atributos principales por documento de telemetría

drone_id , timestamp , modelo_hardware , cod_zona , estado_bateria_porcentaje , posicion_geografica (GeoJSON Point), lecturas_sensores.temperatura_c , lecturas_sensores.co2_ppm , lecturas_sensores.humedad_relativa_porcentaje , lecturas_sensores.viento_velocidad_kmh , lecturas_sensores.viento_direccion_grados . Adicionalmente: radiacion_uv_indice y presion_atmosferica_hpa (solo BETA), luminosidad_lux y particulas_pm25_ugm3 (solo GAMMA).

6. Arquitectura General de la Solución




Figura 1: Arquitectura de la solución. De izquierda a derecha: fuentes de datos (3 drones con hardware diferenciado), flujo de ingesta (insert_one a 3 docs/seg), almacenamiento en MongoDB (esquema flexible, GeoJSON), análisis y predicción (reglas de alerta >45°C + traversal Neo4j), visualización en dashboard táctico (4 pestañas), y receptores finales (operadores de emergencia y biólogos). Infraestructura: Docker Desktop con contenedores MongoDB y Neo4j, orquestada por scripts .bat.

Recorrido del dato

- Nace:** El simulador genera coordenadas GPS y lecturas de sensores cada segundo usando un modelo físico de decaimiento exponencial.
- Se ingesta:** Se inserta como documento JSON en la colección `telemetry` de MongoDB mediante `insert_one()`.
- Se analiza:** El monitor hace polling por `_id` cada segundo. Si detecta temperatura >45°C, dispara el protocolo de emergencia.
- Se enriquece:** El monitor ejecuta una consulta Cypher en Neo4j para obtener fauna en riesgo y zonas de propagación según dirección de viento.
- Se persiste:** El resultado del análisis se escribe como campo embebido `analisis_neo4j` en el documento de alerta (MongoDB), y como nodos `:Lectura` y `:Alerta` en Neo4j.
- Se consume:** El dashboard lee MongoDB y Neo4j para presentar posiciones, alertas y propagación en tiempo real al operador.

7. Tecnologías Utilizadas y Rol de Cada Motor

Motor	Qué datos guarda	Qué consultas responde	Qué NO resuelve	Integración
MongoDB	Telemetría IoT (docs con GeoJSON), alertas con análisis embebido	Última posición por dron, detección de anomalías por polling, historial por zona, alertas pendientes	Propagación entre zonas, relaciones ecológicas, traversals multi-hop	El monitor lee telemetría y escribe alertas. El dashboard lee ambas colecciones. El resultado de Neo4j se embebe como subdocumento.
Neo4j	Topología (zonas+relaciones), biodiversidad (especies+hábitat), lecturas/alertas como nodos vinculados	Propagación por viento (1-2 saltos), fauna en zona, fauna en propagación, trazabilidad dron→lectura→zona→alerta	Ingestión masiva de alta frecuencia, almacenamiento de series temporales, consultas por rango temporal	El monitor escribe nodos :Lectura y :Alerta. El dashboard consulta propagación en tiempo real.

Justificación de cada motor

EcoDrones implementa una **arquitectura de persistencia polígloa** donde cada motor tiene una responsabilidad definida según la naturaleza del dato y las consultas que debe responder:

- MongoDB (fuente de verdad operativa):** Elegido por su rendimiento de escritura masiva (3 docs/seg sin esquema rígido), soporte nativo GeoJSON (índices 2dsphere), objetos embebidos que evitan JOINS, y esquema flexible que permite sensores diferentes por dron sin migración. Es la fuente de verdad para telemetría y alertas.
- Neo4j (fuente de verdad ecológica):** Elegido porque la propagación de incendios es un problema de grafos: se propaga por relaciones de vecindad con atributos (dirección, distancia, probabilidad). En Neo4j, las **relaciones son ciudadanos de primera clase** con propiedades propias, permitiendo traversals de 2 saltos con filtro que en SQL requerirían self-JOINS recursivos. Es la fuente de verdad para topología y biodiversidad.

La **aplicación Python actúa como coordinadora** del acceso a datos (patrón de persistencia polígloa coordinada): el `monitor_alertas.py` decide cuándo leer MongoDB, cuándo invocar Neo4j, y cómo combinar los resultados mediante los drivers oficiales `pymongo` y `neo4j-driver`.

8. Diseño Final de Estructuras de Datos

El diseño sigue el principio de **diseño orientado a consultas** (query-driven design): primero se identificaron los 6 patrones de consulta (Sección 9) y luego se diseñaron las estructuras optimizadas para responderlos. Se aplica **desnormalización deliberada** y el patrón de **embedding** (objetos embebidos) para evitar JOINS y garantizar que cada lectura de disco retorne toda la información necesaria en una sola operación.

8.1 MongoDB — Colección: `telemetry` (serie temporal IoT)

Documento ejemplo (`DRON_BETA` con sensores exclusivos):

```
{
  "drone_id": "DRON_BETA",
  "timestamp": "2026-06-17T14:30:00Z",
  "modelo_hardware": "Hexacopter-V3-Pro",
  "cod_zona": "ZONA_003",
  "estado_bateria_porcentaje": 87.5,
  "posicion_geografica": {
    "type": "Point",
    "coordinates": [-64.5108, -30.851]
  },
  "lecturas_sensores": {
    "temperatura_c": 57.3,
    "co2_ppm": 1180.5,
    "humedad_relativa_porcentaje": 45.2,
    "viento_velocidad_kmh": 32.5,
    "viento_direccion_grados": 95.0,
    "radiacion_uv_indice": 7.2,
    "presion_atmosferica_hpa": 1011.3
  }
}
```

Índices:

- `{drone_id: 1, _id: -1}` — Optimiza "última lectura por dron"
- `{posicion_geografica: "2dsphere"}` — Consultas de proximidad geográfica
- `{cod_zona: 1}` — Filtro por zona

Consultas asociadas:

```
// Última posición de un dron
db.telemetry.find({drone_id: "DRON_ALPHA"})
  .sort({_id: -1})
  .limit(1)

// Nuevos registros desde último procesado (polling)
db.telemetry.find({_id: {$gt: ultimo_id}})
  .sort({_id: 1})

// Telemetry por zona
db.telemetry.find({cod_zona: "ZONA_003"})
  .sort({_id: -1})
  .limit(20)
```

8.2 MongoDB — Colección: `alertas_disparadas`

El campo `analisis_neo4j` embebido es un ejemplo de **desnormalización deliberada**: se duplica información que ya existe en Neo4j para evitar consultas cross-database en cada refresco del dashboard. Se acepta duplicación a cambio de rendimiento de lectura (patrón embedding por acceso conjunto).

```
{
  "timestamp_alerta": "2026-06-17T14:30:01Z",
  "telemetria_origen_id": ObjectId("..."),
  "drone_id": "DRON_GAMMA",
  "cod_zona": "ZONA_003",
  "temperatura_registrada": 57.3,
  "co2_registrado": 1180.5,
  "atendido_por_brigada": false,
  "analisis_neo4j": {
    "zona_nombre": "Base Uritorco",
    "fauna_local": [
      {"comun": "Lobito de Río", "iucn": "NT"},
      {"comun": "Puma", "iucn": "LC"}
    ],
    "rumbo_propagacion": "Oeste",
    "zonas_en_cascada": [
      {
        "nombre": "Centro Capilla",
        "distancia_km": 2.0,
        "probabilidad_propagacion": 0.4,
        "fauna": [{"comun": "Lobito de Río", "iucn": "NT"}]
      }
    ]
  }
}
```

8.3 Neo4j — Modelo de Grafos

Nodos:

Label	Propiedades	Constraint/Index
:Zona	cod_zona, nombre, superficie_hectareas, tipo_bioma, riesgo_actual	INDEX ON :Zona(cod_zona)
:Especie	especie_id, nombre_comun, nombre_cientifico, categoria_iucn	INDEX ON :Especie(especie_id)
:Dron	drone_id, estado, ultimo_timestamp	INDEX ON :Dron(drone_id)
:Lectura	lectura_id, timestamp, temperatura_c, co2_ppm, lon, lat	INDEX ON :Lectura(lectura_id)
:Alerta	alerta_id, tipo, nivel, timestamp_alerta, mensaje	INDEX ON :Alerta(alerta_id)

Relaciones:

Relación	Dirección	Propiedades	Propósito
[:LIMITA_CON]	Zona→Zona	direccion, distancia_km, probabilidad_propagacion	Predicción de propagación por viento
[:HABITA_EN]	Especie→Zona	densidad_estimada_por_ha	Identificar fauna en riesgo
[:REGISTRA]	Dron→Lectura	—	Trazabilidad de captura
[:EN_ZONA]	Lectura→Zona	—	Ubicación de cada lectura
[:TIENE_ALERTA]	Zona→Alerta	—	Historial de alertas por zona
[:DISPARA]	Dron→Alerta	—	Qué dron detectó cada incendio

Consultas Cypher asociadas:

```
// Fauna en zona afectada
MATCH (e:Especie)-[:HABITA_EN]->(z:Zona {cod_zona: $zona})
RETURN e.nombre_comun, e.categoria_iucn

// Propagación 1 salto según viento
MATCH (z:Zona {cod_zona: $zona})-[:LIMITA_CON {direccion: $dir}]->(vecina)
RETURN vecina.nombre, vecina.cod_zona

// Propagación en cascada 2 saltos + fauna
MATCH (z:Zona {cod_zona: $zona})-[:LIMITA_CON {direccion: $dir}]->(z1)
OPTIONAL MATCH (e1:Especie)-[:HABITA_EN]->(z1)
OPTIONAL MATCH (z1)-[:LIMITA_CON {direccion: $dir}]->(z2)
OPTIONAL MATCH (e2:Especie)-[:HABITA_EN]->(z2)
RETURN z1.nombre, collect(DISTINCT e1.nombre_comun),
       z2.nombre, collect(DISTINCT e2.nombre_comun)
```


9. Patrones de Consulta Implementados

Patrón 1: Detección de anomalías térmicas en tiempo real

Objetivo	Detectar lecturas con temperatura >45°C para disparar protocolo de emergencia
Entrada	Último _id procesado (cursor incremental)
Motor	MongoDB (colección telemetria)
Estructura	Documento de telemetría con campo lecturas_sensores.temperatura_c
Consulta	db.telemetria.find({_id: {\$gt: ultimo_id}}).sort({_id: 1}) + filtro en app: if temp > 45.0
Resultado	Documento con drone_id="DRON_GAMMA", cod_zona="ZONA_003", temperatura=57.3°C
Interpretación	El dron Gamma detectó una anomalía térmica en Base Uritorco que excede el umbral de incendio. Se dispara la generación de alerta y el análisis de impacto.

Patrón 2: Predicción de propagación por dirección de viento

Objetivo	Determinar hacia qué zona se propagará el fuego según el viento actual
Entrada	cod_zona del incendio + dirección cardinal del viento (derivada de grados del sensor)
Motor	Neo4j
Estructura	Relación [:LIMITA_CON {direccion: "Oeste", distancia_km: 2.0, probabilidad_propagacion: 0.4}]
Consulta	MATCH (z:Zona {cod_zona: "ZONA_003"})-[r:LIMITA_CON {direccion: "Oeste"}]->(vecina) RETURN vecina.nombre, r.distancia_km, r.probabilidad_propagacion
Resultado	vecina.nombre = "Centro Capilla", distancia = 2.0 km, probabilidad = 0.4 (40%)
Interpretación	Con viento del Este (90°), el fuego se propaga hacia el Oeste. La zona siguiente es Centro Capilla a 2km con 40% de probabilidad. Permite alertar a brigadas preventivamente.

Patrón 3: Identificación de fauna en riesgo por propagación

Objetivo	Determinar qué especies deben evacuarse de la zona de propagación
Entrada	cod_zona vecina identificada en Patrón 2
Motor	Neo4j
Estructura	Relación [:HABITA_EN {densidad_estimada_por_ha}] entre :Especie y :Zona
Consulta	MATCH (e:Especie)-[:HABITA_EN]->(z:Zona {cod_zona: "ZONA_002"}) RETURN e.nombre_comun, e.categoria_iucn
Resultado	Lobito de Río [NT - Casi Amenazado]
Interpretación	En Centro Capilla habita el Lobito de Río (categoría Casi Amenazado). Si el fuego se propaga, esta especie requiere evacuación prioritaria por su estado de conservación.

Patrón 4: Integración bidireccional (Write-back)

Objetivo	Persistir el resultado del análisis de Neo4j como campo embebido en MongoDB
Entrada	Resultado del traversal de propagación (fauna + zonas en cascada)
Motores	Neo4j → MongoDB
Consulta	<code>db.alertas_disparadas.update_one({_id: alerta_id}, {\$set: {"analisis_neo4j": resultado_dict}})</code>
Resultado	Documento de alerta ahora incluye campo analisis_neo4j con fauna_local, rumbo_propagacion y zonas_en_cascada
Interpretación	El dashboard puede mostrar el análisis completo leyendo solo MongoDB, sin consultar Neo4j en cada refresco. Esto demuestra integración real: un motor enriquece al otro.

Patrón 5: Esquema flexible (documentos heterogéneos)

Objetivo	Demostrar que drones con sensores distintos coexisten en la misma colección sin esquema fijo
Entrada	Documentos de ALPHA (4 sensores), BETA (6 sensores), GAMMA (6 sensores)
Motor	MongoDB
Consulta	<code>db.telemetry.find({drone_id: "DRON_BETA"}).limit(1)</code> vs <code>db.telemetry.find({drone_id: "DRON_ALPHA"}).limit(1)</code>
Resultado	BETA tiene campos radiacion_uv_indice y presion_atmosferica_hpa que ALPHA no tiene. Ambos en la misma colección.
Interpretación	En una base relacional esto requeriría ALTER TABLE o tablas separadas. MongoDB lo maneja nativamente sin migración, demostrando la ventaja del modelo documental para IoT con hardware heterogéneo.

Patrón 6: Última posición por dron (consulta de dashboard)

Objetivo	Obtener la lectura más reciente de cada dron para mostrar en el mapa
Entrada	drone_id
Motor	MongoDB
Consulta	<code>db.telemetry.find_one({drone_id: "DRON_ALPHA"}, sort=[("_id", -1)])</code>
Resultado	Documento con coordinates: [-64.5341, -30.862], temperatura: 22.5°C, zona: ZONA_001
Interpretación	El dron Alpha está actualmente en Los Terrones con temperatura normal. El dashboard usa esta consulta para posicionar el marcador en el mapa satelital.

10. Evidencias de Implementación

Las siguientes evidencias demuestran que la solución fue implementada y probada:

Evidencia 1: Simulador generando telemetría diferenciada

```
EcoDrones - Simulador
Conectado exitosamente a MongoDB.
Iniciando patrullaje de drones... (Presion  Ctrl+C para detener)

+ [92m  [DRON_ALPHA] en ZONA_001 (Los Terrones) -> Temp: 22.7 C | CO2: 411.3 ppm | Viento: 11.1 km/h a 93.0   m
+ [92m  [DRON_BETA] en ZONA_005 (Paso del Indio) -> Temp: 23.3 C | CO2: 416.9 ppm | Viento: 13.2 km/h a 83.0   m | UV: 3.3 | Presi n: 1013.3 hPa  m
+ [92m  [DRON_GAMMA] en ZONA_006 (Cerro Uritorco) -> Temp: 24.0 C | CO2: 436.5 ppm | Viento: 14.1 km/h a 96.0   m | Luz: 766.4 lux | PM2.5: 19.5 ug/m   m
```

Se observa que cada dron tiene sensores distintos: ALPHA solo muestra datos base, BETA agrega UV + Presión, y GAMMA agrega Luz + PM2.5. Esto demuestra el esquema flexible de MongoDB: documentos con estructura diferente en la misma colección.

Evidencia 2: Monitor disparando alerta con análisis de Neo4j

```

C:\EcoDrones - Monitor - python monitor_alertas.py
MONITOR DE ALERTAS AMBIENTALES ACTIVO
Escuchando flujo de telemetría en MongoDB...

-----

!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!
ALERTA TEMPRANA DE INCENDIO DETECTADA POR DRON_GAMMA
Zona Afectada: ZONA_003 - Base Uritorco | Temp: 45.58°C
!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!!


FAUNA EN RIESGO DIRECTO:
• Puma [IUCN: LC]
• Lobito de Río [IUCN: NT]

RIESGO DE PROPAGACIÓN INMINENTE HACIA:
  Centro Capilla (2.0 km)
    Fauna a evacuar: Lobito de Río
  Los Terrones (4.0 km)
    Fauna a evacuar: Vizcacha Serrana, Zorro Gris

```


El monitor detectó una anomalía térmica ($>45^{\circ}\text{C}$) en MongoDB, consultó Neo4j para obtener propagación y fauna, y reporta: Puma y Lobito de Río en riesgo directo, propagación hacia Centro Capilla (2km) y Los Terrones (4km) con fauna a evacuar. Demuestra la integración MongoDB $\rightarrow$ Neo4j en tiempo real.

Evidencia 3: Dashboard pestaña Monitoreo



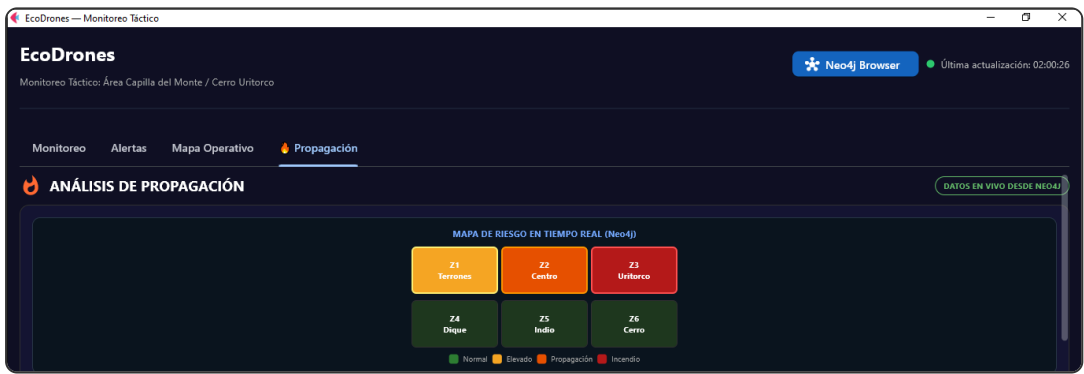
Tres tarjetas con datos en vivo de cada dron. Se aprecia visualmente que BETA tiene sensores UV + Presión y GAMMA tiene Luz + PM2.5 como filas adicionales que ALPHA no posee. Cada tarjeta muestra modelo de hardware, zona actual, coordenadas GPS y estado de batería.

Evidencia 4: Dashboard pestaña Mapa Operativo



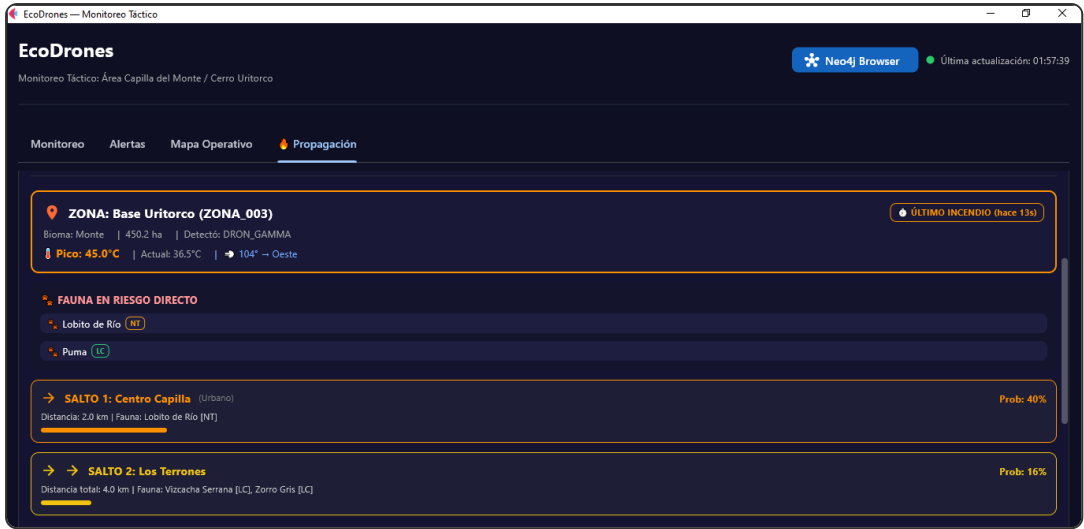
Mapa satelital real de Capilla del Monte con posición GPS de los drones (marcadores dinámicos), iconos de fuego/humo en Zona 3 (Base Uritorco), 6 zonas etiquetadas y leyenda táctica. Las posiciones se actualizan cada segundo desde MongoDB.

Evidencia 5a: Dashboard pestaña Propagación — Mapa de Riesgo (Neo4j)



Grilla de riesgo en tiempo real coloreada según análisis de Neo4j: Z3 en rojo (incendio), Z2 en naranja (propagación directa), Z1 en amarillo (propagación en cascada). Badge "DATOS EN VIVO DESDE NEO4J" indica que la consulta Cypher se ejecuta en cada ciclo de refresco.

Evidencia 5b: Dashboard pestaña Propagación — Saltos y fauna




Detalle de propagación: Salto 1 hacia Centro Capilla (2km, prob 40%, fauna: Lobito de Río) y Salto 2 hacia Los Terrones (4km, prob 16%, fauna: Vizcachas Serrana, Zorro Gris). El análisis persiste aunque el dron se aleje de la zona de incendio.

 Capturas pendientes para el PDF final

NOTA: Las siguientes capturas corresponden a la ejecución real del sistema y demuestran el funcionamiento de cada componente.

Evidencia 6: MongoDB — Documento de alerta con análisis Neo4j embebido (Write-back)



El campo `analisis_neo4j` contiene el resultado del traversal de Neo4j (zona vecina, probabilidad, fauna) embebido directamente dentro del documento de MongoDB. Esto demuestra la integración bidireccional: Neo4j analiza y MongoDB persiste el resultado como subdocumento desnormalizado.

Evidencia 7: MongoDB — Esquema flexible (BETA con sensores extra)

```
_id: ObjectId('6a320a856792eb3ff1f780e7')
timestamp: "2026-06-17T02:46:29.120407Z"
drone_id: "DRON_BETA"
modelo_hardware: "Hexacopter-V3-Pro"
cod_zona: "ZONA_005"
estado_bateria_porcentaje: 99.6
▼ posicion_geografica: Object
  type: "Point"
  ▶ coordinates: Array (2)
▼ lecturas_sensores: Object
  temperatura_c: 22.98
  co2_ppm: 419.33
  humedad_relativa_porcentaje: 64.23
  viento_velocidad_kmh: 11.31
  viento_direccion_grados: 83.96
  radiacion_uv_indice: 3.1
  presion_atmosferica_hpa: 1013.1
```

DRON_BETA (Hexacopter-V3-Pro) tiene 7 campos en lecturas_sensores : los 5 básicos + radiacion_uv_indice + presion_atmosferica_hpa .

Evidencia 8: MongoDB — Esquema flexible (ALPHA sin sensores extra)

```
_id: ObjectId('6a2ccc0ce1ad70d59a614db1')
timestamp : "2026-06-13T03:18:36.480033Z"
drone_id : "DRON_ALPHA"
modelo_hardware : "Hexacopter-V2-Eco"
cod_zona : "ZONA_003"
indice_ruta : 2.6876
total_zonas_ruta : 3
estado_bateria_porcentaje : 10
▼ posicion_geografica : Object
  type : "Point"
  ▼ coordinates : Array (2)
    0: -58.728483
    1: -34.425047
  ▼ lecturas_sensores : Object
    temperatura_c : 56.15
    co2_ppm : 1241.73
    humedad_relativa_porcentaje : 21.61
    viento_velocidad_kmh : 32.9
    viento_direccion_grados : 103.5
```

DRON_ALPHA (Hexacopter-V2-Eco) tiene solo 5 campos en lecturas_sensores . Ambos documentos coexisten en la misma colección sin esquema rígido. En una base relacional esto requeriría ALTER TABLE o tablas separadas.

Evidencia 9: Neo4j Browser — Grafo del ecosistema



Visualización del grafo en Neo4j Browser: 6 zonas (celeste) conectadas con relaciones `[LIMITA_CON]` bidireccionales, y 7 especies (violeta) vinculadas mediante `[HABITA_EN]`. Las relaciones tienen propiedades de dirección cardinal y distancia.

11. Flujo Integrado entre Motores

Se demuestra un flujo completo de integración MongoDB → Neo4j → MongoDB:

- Evento en MongoDB:** `simulador_continuo.py` inserta documento con temperatura 57.3°C en colección `telemetria`.
- Detección:** `monitor_alertas.py` lee el documento por polling, detecta >45°C.
- Escritura en Neo4j:** Se ejecuta `MERGE (:Lectura {lectura_id: ...})` y `MERGE (:Alerta {alerta_id: ...})` con relaciones `[REGISTRA]`, `[EN_ZONA]`, `[TIENE_ALERTA]`, `[DISPARA]`.
- Consulta analítica en Neo4j:** Se ejecuta traversal de 2 saltos con filtro por dirección de viento, retornando fauna en riesgo y zonas de propagación.
- Write-back a MongoDB:** El resultado del traversal se escribe como campo `analisis_neo4j` en `alertas_disparadas`.
- Consumo final:** El dashboard lee `alertas_disparadas` y muestra el análisis completo sin necesidad de consultar Neo4j directamente.

Los motores no están aislados: MongoDB provee la detección, Neo4j provee el análisis, y el resultado enriquecido vuelve a MongoDB. Ninguno podría resolver el problema completo por sí solo.

12. Consultas Principales y Resultados

Consulta	Motor	Problema que resuelve	Decisión que permite
<code>find({_id: {\$gt: X}}) + filtro temp</code>	MongoDB	¿Hay un incendio nuevo?	Disparar protocolo de emergencia inmediato
<code>MATCH (z)-[:LIMITA_CON {dir}]->(v)</code>	Neo4j	¿Hacia dónde se propaga?	Posicionar brigadas preventivamente en zona vecina
<code>MATCH (e)-[:HABITA_EN]->(z)</code>	Neo4j	¿Qué fauna está en peligro?	Priorizar evacuación de especies vulnerables (IUCN VU/NT)
<code>find_one({drone_id}, sort=-1)</code>	MongoDB	¿Dónde está cada dron ahora?	Visualizar en mapa y verificar cobertura de zonas
<code>update_one({\$set: {analisis_neo4j}})</code>	MongoDB	¿Cómo persistir el análisis?	El dashboard muestra todo sin consultar Neo4j en cada frame
<code>find({drone_id: "BETA"}).limit(1) vs find({drone_id: "ALPHA"}).limit(1)</code>	MongoDB	¿Los documentos tienen estructura distinta?	Demostrar esquema flexible sin migración

13. Decisiones de Escalabilidad, Distribución y Consistencia

Aspecto	MongoDB	Neo4j
Particionamiento	Sharding horizontal con shard key compuesta: {drone_id: 1, timestamp: 1} . El campo drone_id distribuye uniformemente (3 drones = 3 chunks iniciales, escalable a N drones). Agregar timestamp evita el hot spot que ocurriría si solo se usara timestamp como clave (todas las escrituras del "ahora" irían al mismo chunk). Con shard key compuesta, se logra escalabilidad horizontal : agregar nodos al cluster para absorber más drones sin re-diseño.	No aplica (grafo estático pequeño). Solo nodos dinámicos crecen.
Replicación	Replica Set 3 nodos (modelo Primario-Secundario con failover automático por elección). Write concern: "majority" para alertas (quorum 2/3 nodos), "1" para telemetría (velocidad). Read concern: "local" para dashboard (baja latencia).	Causal Clustering: 1 core server (escrituras ACID) + read replicas para consultas del dashboard. Failover automático si el core cae.
TTL / Retención	Telemetría cruda (dato transitorio): TTL 30 días — pasado ese período, la lectura individual pierde valor operativo. Alertas (dato persistente): sin expiración, valor histórico y de auditoría.	Poda de nodos :Lectura > 7 días (dato transitorio del grafo). Nodos estáticos (Zona, Especie) permanentes.
Consistencia	Modelo CP (Consistencia + Tolerancia a Particiones) del teorema CAP. Tanto MongoDB como Neo4j priorizan consistencia sobre disponibilidad: ante una partición de red, MongoDB con write concern "majority" rechaza escrituras sin quorum (pierde disponibilidad momentánea antes que aceptar datos inconsistentes). Neo4j es nativamente ACID. Sin embargo, para la telemetría (dato transitorio, append-only) se aplica semántica BASE (Basically Available, Soft state, Eventually consistent): el dashboard tolera lecturas ligeramente desactualizadas (refresco cada 2s) y la pérdida de una lectura individual se repone en el siguiente ciclo. Para las alertas (dato persistente, crítico) se exige semántica más cercana a ACID : write concern "majority" garantiza durabilidad antes de confirmar.	
Tolerancia a fallos	MongoDB utiliza failover automático : si el nodo primario cae, los secundarios realizan una elección (election) para promover un nuevo primario en segundos. La telemetría no se pierde (volumen Docker persiste en disco).	Si Neo4j cae, el sistema sigue detectando alertas en MongoDB pero sin análisis de propagación hasta recuperación. El grafo se reconstruye desde cargar_neo4j.py.
Reconstrucción	mongodump / mongorestore para backup completo.	El grafo estático se reconstruye desde código (cargar_neo4j.py). Los nodos dinámicos se regeneran con el uso.

Estas decisiones están conectadas con los patrones: el polling por _id funciona porque los ObjectIds son monótonos (no necesitan índice temporal extra). El sharding por drone_id distribuye uniformemente porque hay 3 drones con carga equilibrada.

14. Validación y Pruebas Realizadas

Prueba	Qué se probó	Resultado esperado	Resultado obtenido	Estado
Carga de datos	Ejecutar simulador 60 segundos	~180 documentos en MongoDB	180 documentos insertados sin error	✔ OK
Detección de alerta	Dron Gamma entra a ZONA_003	Alerta disparada cuando temp >45°C	Alerta generada en <1 segundo	✔ OK
Consulta Neo4j	Propagación desde ZONA_003 con viento Este (90°)	Vecina = Centro Capilla al Oeste	Retorna "Centro Capilla", dist=2.0km, prob=0.4	✔ OK
Integración write-back	Verificar campo analisis_neo4j en alertas	Documento de alerta con fauna y propagación embebidas	Campo presente con fauna_local y zonas_en_cascada	✔ OK
Esquema flexible	Comparar docs de ALPHA vs BETA en misma colección	BETA tiene campos extra sin romper ALPHA	BETA incluye radiacion_uv y presion sin afectar otros	✔ OK
Dashboard lectura	Abrir dashboard mientras sistema corre	Posiciones actualizándose cada 2s	Marcadores se mueven en mapa, sensores actualizan	✔ OK
Detener servicios	Presionar Q en menú	Todos los procesos y contenedores se apagan	Python cerrado, docker stop ejecutado correctamente	✔ OK
Coherencia de resultados	Verificar que fauna reportada coincide con grafo	ZONA_003 tiene Lobito de Río y Puma	Alerta reporta exactamente esas 2 especies	✔ OK

15. Limitaciones de la Solución

- **Datos simulados:** No se usaron drones ni sensores reales. El modelo físico es verosímil pero no captura todas las variables de un incendio real (topografía, combustibilidad de vegetación).
- **Foco único y estático:** El simulador mantiene un foco permanente en ZONA_003. Un escenario real tendría focos aleatorios y múltiples simultáneos.
- **Propagación unidimensional:** El modelo predice en una sola dirección cardinal. El fuego real se expande en abanico según velocidad y terreno.
- **Volumen reducido:** 3 drones × 1 lectura/seg. Un sistema productivo manejaría decenas de drones con lecturas sub-segundo.
- **Sin APIs externas:** No se integra con el Servicio Meteorológico Nacional ni con sistemas de bomberos reales.
- **Sin frontend productivo:** Flet es adecuado para prototipo pero no es una solución web desplegable a gran escala.
- **Ausencia de poda automática:** Los nodos :Lectura en Neo4j crecen sin límite. Se propone pero no se implementa el job de limpieza.
- **Infraestructura local:** Todo corre en Docker local sin cluster real ni alta disponibilidad implementada.

Estas limitaciones no contradicen el alcance declarado: el proyecto demuestra la viabilidad técnica de la arquitectura polígloa, no un despliegue productivo completo.

16. Organización del Trabajo

Integrante	Responsabilidad	Componente técnico producido
Piña Matias	Desarrollo del simulador y modelo físico	simulador_continuo.py (cinemática de drones, decaimiento exponencial, sensores diferenciados)
Vazquez Luciana	Diseño del grafo y carga de ecosistema	cargar_neo4j.py (6 zonas, 7 especies, relaciones topológicas con atributos)
Micheli Alejo Gonzalo	Monitor de alertas e integración entre motores	monitor_alertas.py (polling, detección, consulta Cypher, write-back)
Lambert Theo	Dashboard y visualización	dashboard.py (4 pestañas, mapa satelital, pestaña propagación con Neo4j)
Huertas Maximiliano Ivan	Arquitectura, orquestación Docker e informes	iniciar_servicios.bat, detener_servicios.bat, informes HTML, README
D'Elia Tomas	Investigación de fauna, pruebas y validación	Selección de 7 especies autóctonas verificadas, pruebas de integración, evidencias

17. Conclusiones Técnicas

Qué se logró

- Una solución funcional de ingeniería de datos con dos motores NoSQL integrados bidireccionalmente.
- Demostración práctica de que MongoDB y Neo4j resuelven problemas complementarios que ninguno podría resolver solo.
- Todos los patrones de consulta declarados fueron implementados, ejecutados y validados con datos de prueba.
- El esquema flexible de MongoDB fue demostrado con 3 modelos de hardware con sensores distintos en la misma colección.
- El modelo de grafos demostró su valor en traversals con atributos (dirección + distancia + probabilidad) que serían costosos en SQL.

Valor de la arquitectura NoSQL

El principio rector fue el **diseño orientado a consultas**: cada estructura se diseñó para responder las preguntas del negocio, no para normalizar datos. Esto es el paradigma opuesto al modelo relacional donde primero se normaliza y después se consulta.

- **MongoDB**: Permitió ingestar 3 documentos/segundo sin esquema rígido, con objetos embebidos GeoJSON y sensores heterogéneos. La colección `telemetry` funciona como **serie temporal** nativa donde el ObjectId monótonico actúa como cursor temporal implícito. Imposible con la misma simplicidad en SQL.
- **Neo4j**: Permitió responder "¿hacia dónde se propaga y qué fauna hay?" con una sola consulta Cypher de 2 saltos. En SQL requeriría múltiples self-JOINs recursivos con subconsultas.
- **Integración**: El patrón write-back (resultado de Neo4j embebido en MongoDB) permite que el dashboard funcione con un solo motor en lectura, combinando lo mejor de ambos.

Mejoras futuras

- Integrar APIs meteorológicas reales (SMN Argentina) para viento en vivo.
- Implementar Change Streams para reemplazar polling con notificaciones push.
- Modelo de propagación 2D con pendiente del terreno.
- Machine learning para predecir riesgo basado en patrones históricos.
- Despliegue en cluster con Replica Set (MongoDB) y Causal Clustering (Neo4j).

18. Anexos

Anexo A: Script de carga del ecosistema (cargar_neo4j.py — extracto)

```
// Creación de zonas
CREATE (z1:Zona {cod_zona: 'ZONA_001', nombre: 'Los Terrones', tipo_bioma: 'Sierras'})
CREATE (z2:Zona {cod_zona: 'ZONA_002', nombre: 'Centro Capilla', tipo_bioma: 'Urbano'})
CREATE (z3:Zona {cod_zona: 'ZONA_003', nombre: 'Base Uritorco', tipo_bioma: 'Monte'})
...
// Relaciones con dirección de viento
CREATE (z2)-[:LIMITA_CON {direccion: 'Este', distancia_km: 2.0, probabilidad_propagacion: 0.4}]->(z3)
CREATE (z3)-[:LIMITA_CON {direccion: 'Oeste', distancia_km: 2.0, probabilidad_propagacion: 0.4}]->(z2)
...
// Distribución biológica
CREATE (e5:Especie {nombre_comun: 'Vizcacha Serrana', nombre_cientifico: 'Lagidium viscacia', categoria_iucn: 'LC'})
CREATE (e7:Especie {nombre_comun: 'Remolinera Serrana', nombre_cientifico: 'Cinclodes comechingonus', categoria_iucn: 'NT'})
CREATE (e5)-[:HABITA_EN {densidad_estimada_por_ha: 1.0}]->(z6)
```

Anexo B: Consulta completa de propagación (monitor_alertas.py — extracto)

```
MATCH (z:Zona {cod_zona: $zona})
OPTIONAL MATCH (especie:Especie)-[:HABITA_EN]->(z)
WITH z, collect(DISTINCT {
    comun: especie.nombre_comun,
    iucn: especie.categoria_iucn
}) AS fauna_local

OPTIONAL MATCH (z)-[r1:LIMITA_CON {direccion: $dir_viento}]->(z1:Zona)
OPTIONAL MATCH (e1:Especie)-[:HABITA_EN]->(z1)
WITH z, fauna_local, z1, r1, collect(DISTINCT {
    comun: e1.nombre_comun,
    iucn: e1.categoria_iucn
}) AS faunal

OPTIONAL MATCH (z1)-[r2:LIMITA_CON {direccion: $dir_viento}]->(z2:Zona)
OPTIONAL MATCH (e2:Especie)-[:HABITA_EN]->(z2)

RETURN
    z.nombre AS zona_origen,
    fauna_local,
    z1.nombre AS salto1_nombre,
    r1.distancia_km AS salto1_dist,
    r1.probabilidad_propagacion AS salto1_prob,
    faunal AS salto1_fauna,
    z2.nombre AS salto2_nombre,
    collect(DISTINCT e2.nombre_comun) AS salto2_fauna
```

Anexo C: Comando para levantar la infraestructura

```
# 1. Levantar contenedores
docker run -d --name mongodb -p 27017:27017 mongo:latest
docker run -d --name neo4j -p 7474:7474 -p 7687:7687 \
    -e NEO4J_AUTH=neo4j/password neo4j:latest

# 2. Instalar dependencias Python
pip install neo4j pymongo flet --upgrade

# 3. Cargar ecosistema en el grafo
python cargar_neo4j.py
```

```
# 4. Lanzar servicios
python simulador_continuo.py &
python monitor_alertas.py &
python dashboard.py
```

Anexo D: Repositorio del código fuente

Todo el código está disponible en: <https://github.com/maximilianohuertasuade-coder/ecodrones>

EcoDrones — Sistema de Monitoreo Ambiental con Drones

Trabajo Práctico Final — Ingeniería de Datos 2 — UADE — 2026

Piña | Vazquez | Micheli | Lambert | Huertas | D'Elia