



Unidad 6 Clase 12

Grandes Volúmenes de Datos

BIG DATA Y VISIÓN SISTÉMICA DE LA INGENIERÍA DE DATOS


Comprender el rol del Big Data y del ecosistema Hadoop en arquitecturas modernas de datos, analizando la integración de estructuras NoSQL con Data Marts y comparando su rendimiento frente a soluciones relacionales.

Big Data y la Visión Sistémica en la Ingeniería de Datos

Más allá del volumen: la complejidad del ecosistema digital.



El Mito: Big Data no significa únicamente almacenar muchos datos.



La Realidad Profesional: Es el punto de inflexión arquitectónico donde el ecosistema digital supera las capacidades tradicionales de almacenamiento y procesamiento computacional.

El Cambio de Paradigma:

Se requiere un enfoque sistémico cuando las dimensiones de Volumen, Velocidad, Variedad, Veracidad y Valor convergen y desbordan el modelo relacional clásico.

La Evolución del Contexto Profesional


Del control transaccional al desafío del rastro digital.



El Entorno Relacional (Controlado)

- **Datos:** Ventas, clientes, facturas, inventario.
- **Naturaleza:** Estructurados, predecibles, transaccionales.
- **Arquitectura:** Motores RDBMS (ej. SQL Server, PostgreSQL, Oracle).

Veredicto: Funciona perfectamente para operar el núcleo del negocio con consistencia e integridad.



El Entorno Big Data (Dinámico)

- **Datos:** Logs de aplicaciones, lecturas de sensores IoT, clics de navegación, documentos, eventos digitales históricos.
- **Naturaleza:** Semiestructurados, no estructurados, continuos y masivos.

El Desafío: El problema deja de ser solo registrar una transacción oficial y pasa a ser capturar y dar sentido a la huella digital completa.


Las Dimensiones del Big Data: Impacto en la Arquitectura

Las V no son definiciones académicas; son puntos de fricción técnica.

Dimensión	Contexto Operativo	Problema Arquitectónico Real
Volumen	Millones de registros históricos acumulados.	Problema: Escalamiento insostenible de costos de infraestructura y límites físicos de capacidad en discos tradicionales.
Velocidad	Ingesta continua en tiempo real (ej. sensores IoT).	Problema: Latencia crítica en el procesamiento, cuellos de botella en redes y caída general de rendimiento operativo.
Variedad	JSON, Logs, Video, CSV, APIs externas.	Problema: Imposibilidad de usar esquemas rígidos predefinidos; alta complejidad en la integración de silos de información.
Veracidad	Datos ruidosos, incompletos, inconsistentes o manipulados.	Problema: Falta de gobierno de datos; baja calidad que contamina modelos predictivos y analíticos.
Valor	Necesidad de insights accionables para el negocio.	Problema: Riesgo de almacenar basura digital sin un Retorno de Inversión (ROI) claro para la toma de decisiones.


Limitaciones de la Arquitectura Tradicional

El riesgo crítico de concentrar responsabilidades en un único servidor.



Paradigma de Arquitectura Distribuida

Separación de responsabilidades a través del ciclo de vida del dato.




Redefiniendo el Rol en Ingeniería de Datos II

De la selección de motores al diseño estratégico de ecosistemas de datos.

El Enfoque Obsoleto: Preguntar simplemente ¿qué tabla o motor de base de datos uso? para todo el sistema.

El Enfoque Moderno (Big Data): Diseñar una arquitectura completa, distribuida y por capas, respondiendo a requerimientos complejos de negocio y sistema.

Variables de Decisión Arquitectónica



Síntesis Conceptual

Big Data como facilitador de inteligencia corporativa.

Perspectiva Académica: Big Data debe comprenderse como una respuesta profesional e ingenieril a los problemas críticos de escala, diversidad de formatos y fricción operativa.

El Fin Último: La tecnología subyacente (Hadoop, Spark, Data Lakes) es únicamente el medio estructural para habilitar decisiones informadas, modelos predictivos y eficiencia corporativa.

“El desafío no es almacenar más datos, sino convertir datos masivos y diversos en conocimiento útil, gobernado y accionable.”

Apache Hadoop: La Respuesta Histórica al Big Data

Qué es (y qué no es) el estándar fundacional del procesamiento masivo.

Lo que NO es



No es una Base de Datos:

No es un motor transaccional de baja latencia ni reemplaza directamente a SQL Server u Oracle.



No es una herramienta de Reporting:


No es software de Business Intelligence (BI) para crear dashboards interactivos.



No es una aplicación monolítica:

No se instala como un programa tradicional aislado en un solo servidor de hardware propietario.

Lo que Sí es



Un Ecosistema Open-Source:

Un framework modular gestionado por Apache Software Foundation.



Almacenamiento Distribuido:

Diseñado para ingestar petabytes de datos crudos (estructurados y no estructurados) con alta tolerancia a fallos.




Procesamiento Paralelo:

Capacidad de dividir y ejecutar cálculos masivos simultáneamente en clústeres de hardware estándar.


El Principio de Localidad de Datos

Acercar el procesamiento al dato, en lugar de mover el dato al procesamiento.

Enfoque Clásico: Mover grandes volúmenes de datos a la máquina de cómputo. Lento, costoso y limitado por el ancho de banda.




Divide y Vencerás: Repartir el trabajo en paralelo. Rápido, escalable y tolerante a fallos.



HDFS: La Capa de Almacenamiento

División, distribución y alta tolerancia a fallos mediante el Hadoop Distributed File System.



Características Clave



Tolerancia a fallos

Los bloques se replican (por defecto 3 veces) en distintos nodos y racks. Si un hardware estándar falla, el sistema se recupera automáticamente usando las copias redundantes.




Rendimiento

Optimizado para el acceso secuencial de archivos enormes, priorizando el ancho de banda por encima de la latencia interactiva.

YARN: La Gestión de Recursos


Yet Another Resource Negotiator: El administrador global del clúster Hadoop.

YARN evolucionó a Hadoop de un sistema rígido a una plataforma multipropósito, permitiendo que distintas tecnologías (MapReduce, Spark, etc.) compartan la misma infraestructura sin colisionar.



MapReduce: El Motor de Procesamiento Clásico


Lógica fundacional de procesamiento paralelo en grandes clústeres.



Nota: Aunque hoy convive con motores más modernos, MapReduce es el modelo conceptual que enseñó a la industria cómo procesar petabytes sin colapsar la memoria de una máquina.

El Ecosistema Hadoop y Big Data

Herramientas especializadas que potencian y expanden el núcleo base.



¿Cómo se accede y utiliza Hadoop?

Diferentes interfaces prácticas para diferentes perfiles técnicos.



1. Interfaces Nativas / Consola

Comandos HDFS por terminal e interfaces web de administración (NameNode, YARN) para Ingenieros y Administradores.



2. Lenguajes y Consultas

Uso de HiveQL (sintaxis SQL) o scripts en Python, Scala y Java (vía Spark) para Analistas de Datos.



3. Entornos Interactivos

Uso de Notebooks (Jupyter, Zeppelin) para experimentación iterativa y Ciencia de Datos.



4. Servicios Cloud Administrados

Infraestructura como servicio (AWS EMR, Google Dataproc, Azure HDInsight) para evitar la administración manual del hardware.

“Hadoop se accede, gestiona y diseña como un ecosistema de datos distribuido, no como una aplicación de software tradicional.”

Adopción de Big Data: Una Decisión de Arquitectura, No de Moda

The Traditional World



The Tipping Point



The Big Data Triggers



El criterio profesional no es la cantidad de datos, sino la necesidad técnica de resolver un problema de negocio.

Capacidades Técnicas que Impulsan el Negocio

Tecnología: HDFS y YARN

Infraestructura Resiliente (El Cimiento)

- Escalabilidad horizontal (crecer sumando nodos económicos)
- Tolerancia a fallos automática (redundancia que protege la operación)

Tecnología: MapReduce y Spark

Procesamiento Ágil (El Motor)

- Almacenamiento de datos crudos (Data Lake) integrando múltiples formatos
- Procesamiento paralelo masivo para transformar la información

Tecnología: Hive y BI

Impacto Analítico (El Resultado)

- Preparación ágil de bases masivas para analítica avanzada
- Entrenamiento de modelos predictivos
- Alimentación de tableros de negocio

Límites y Riesgos: Lo que Hay Debajo de la Superficie

Promesa Big Data: Almacenamiento infinito y procesamiento paralelo.

Complejidad y Talento

Alta complejidad operativa que exige perfiles técnicos hiper-especializados (ingenieros de datos, arquitectos).

Gobierno y Calidad

Riesgo crítico de crear un "pantano de datos" inmanejable sin linaje, diccionarios, trazabilidad ni calidad.

Seguridad y Privacidad


Necesidad imperiosa de políticas estrictas de acceso, cifrado (Kerberos) y anonimización de datos sensibles.

Costo Total de Propiedad (TCO)

Gastos ocultos de infraestructura distribuida, licenciamiento cloud, mantenimiento y monitoreo constante.

Riesgo Principal: Sobredimensionar la solución. No incorpore el ecosistema Hadoop si su caso de uso no lo justifica verdaderamente.

Arquitectura Políglota: La Herramienta Correcta para el Trabajo Correcto



Aplicación Real: Descifrando el Comportamiento en E-commerce

Pista Superior:
El Mundo Relacional
(Lo Evidente)

Registra la transacción formal.
Responde a: "¿Qué se compró?"



Pista Inferior:
El Mundo Big Data
(El Contexto Oculto)



Registra millones de micro-interacciones.
Responde a: "¿Por qué no compró?"


Spark y Hive cruzan ambos mundos para transformar el comportamiento crudo en métricas de conversión, modelos de recomendación y segmentación de usuarios.

Aplicación Real: Control Interno y Auditoría Continua

El Problema: Procesar millones de registros desconectados.

Filter Funnel

La Solución Big Data:
Hadoop y Spark
ejecutando reglas
complejas en paralelo.



Principios para el éxito en ingeniería de datos





Práctica de laboratorio:

PySpark - Bigdata

Tomar un conjunto de datos crudo, revisar su estructura, identificar problemas básicos de calidad, transformar columnas relevantes y generar una salida preparada para análisis posterior.

La finalidad es realizar un análisis comercial profundo, y comprender cómo un motor como PySpark puede utilizarse para procesar datos de manera más escalable, simulando una primera etapa de trabajo dentro de una arquitectura Big Data vinculada al ecosistema Hadoop.



PROXIMA CLASE

Clase 13 - Ecosistema Big Data y cierre integrador de la materia

Tema:

Hadoop procesamiento distribuido.
Integración de estructuras NoSQL en Data Marts.
Comparación de rendimientos con estructuras relacionales.
Cierre conceptual de la materia.
